

PHÂN TÍCH THỐNG KÊ NHIỀU CHIỀU (MAT3452)

Bài tập tuần 6: Phương pháp làm giảm số chiều dữ liệu

Trần Đăng Quang Minh - MSV: 23000141

Câu 1. Tập dữ liệu **USJudgeRatings datasets** trong R gồm 12 chỉ số đánh giá cho 43 thẩm phán. Sử dụng dữ liệu trên, hãy cho biết:

(1) Thực hiện phân tích thành phần chính trên tập dữ liệu, hãy cho biết nếu dùng 5 thành phần chính đầu thì tỉ lệ dữ liệu là bao nhiêu?

```
library(datasets)
```

```
df <- USJudgeRatings
head(df)
```

```
##           CONT INTG DMNR DILG CFMG DECI PREP FAMI ORAL WRIT PHYS RTEN
## AARONSON,L.H.  5.7  7.9  7.7  7.3  7.1  7.4  7.1  7.1  7.1  7.0  8.3  7.8
## ALEXANDER,J.M.  6.8  8.9  8.8  8.5  7.8  8.1  8.0  8.0  7.8  7.9  8.5  8.7
## ARMENTANO,A.J.  7.2  8.1  7.8  7.8  7.5  7.6  7.5  7.5  7.3  7.4  7.9  7.8
## BERDON,R.I.    6.8  8.8  8.5  8.8  8.3  8.5  8.7  8.7  8.4  8.5  8.8  8.7
## BRACKEN,J.J.   7.3  6.4  4.3  6.5  6.0  6.2  5.7  5.7  5.1  5.3  5.5  4.8
## BURNS,E.B.     6.2  8.8  8.7  8.5  7.9  8.0  8.1  8.0  8.0  8.0  8.6  8.6
```

```
# Phân tích thành phần chính
```

```
pca <- princomp(df)
summary(pca)
```

```
## Importance of components:
##           Comp.1      Comp.2      Comp.3      Comp.4      Comp.5
## Standard deviation  2.9944812  0.97631616  0.54821237  0.46436892  0.260897305
## Proportion of Variance 0.8476102  0.09010189  0.02840865  0.02038352  0.006434164
## Cumulative Proportion 0.8476102  0.93771205  0.96612070  0.98650423  0.992938391
##           Comp.6      Comp.7      Comp.8      Comp.9
## Standard deviation  0.172098999  0.127444176  0.107411902  0.0862216855
## Proportion of Variance 0.002799688  0.001535299  0.001090581  0.0007027259
## Cumulative Proportion 0.995738079  0.997273378  0.998363959  0.9990666848
##           Comp.10      Comp.11      Comp.12
## Standard deviation  0.0703843063  0.0550575991  0.0434546479
## Proportion of Variance 0.0004682789  0.0002865415  0.0001784947
## Cumulative Proportion 0.9995349638  0.9998215053  1.0000000000
```

```
# Nếu dùng 5 thành phần chính
```

```
sum(pca$sdev[1:5]^2) / sum(pca$sdev^2)
```

```
## [1] 0.9929384
```

(2) Gọi 5 thành phần chính là Y_1 đến Y_5 . Hãy cho biết biến “CONT” và “CFMG” đóng góp bao nhiêu trong mỗi thành phần trên.

```
contribution <- loadings(pca)[c("CONT", "CFMG"), 1:5]
colnames(contribution) <- c("Y1", "Y2", "Y3", "Y4", "Y5")
contribution
```

```
##           Y1           Y2           Y3           Y4           Y5
## CONT  0.00599117  0.9332488  0.3198540  0.11293271  0.09462326
```

```
## CFMG -0.27201855 0.1631993 -0.1893545 -0.02481803 -0.47964024
```

(3) Vẽ biểu đồ tỉ lệ các thành phần trong trường hợp phân tích trên tập dữ liệu và sử dụng ma trận tương quan.

```
library(showtext)
```

```
## Loading required package: sysfonts
```

```
## Loading required package: showtextdb
```

```
font_add("LM", "C:/Windows/Fonts/cambria.ttc")
showtext_auto()
```


```
pcacov <- princomp(df, cor = TRUE)
summary(pcacov, cor = TRUE)
```

```
## Importance of components:
```

```
##               Comp.1      Comp.2      Comp.3      Comp.4      Comp.5
## Standard deviation  3.1833165 1.05078398 0.5769763 0.50383231 0.290607615
## Proportion of Variance 0.8444586 0.09201225 0.0277418 0.02115392 0.007037732
## Cumulative Proportion 0.8444586 0.93647089 0.9642127 0.98536661 0.992404341
##               Comp.6      Comp.7      Comp.8      Comp.9
## Standard deviation  0.193095982 0.140295449 0.124158319 0.0885069038
## Proportion of Variance 0.003107172 0.001640234 0.001284607 0.0006527893
## Cumulative Proportion 0.995511513 0.997151747 0.998436354 0.9990891437
##               Comp.10     Comp.11     Comp.12
## Standard deviation  0.0749114592 0.0570804224 0.0453913429
## Proportion of Variance 0.0004676439 0.0002715146 0.0001716978
## Cumulative Proportion 0.9995567876 0.9998283022 1.0000000000
```


```
prop_var1 <- pca$sdev^2 / sum(pca$sdev^2)
plot(prop_var1,
     col = "red",
     cex = 2,
     lwd = 2,
     type = "b",
     xlab = "Thành phần chính",
     ylab = "Tỉ lệ",
     main = "Tỉ lệ các thành phần (phân tích trên bộ dữ liệu)"
)
```

Tỉ lệ các thành phần (phân tích trên bộ dữ liệu)



```
prop_var2 <- pcacov$sdev^2 / sum(pcacov$sdev^2)
plot(prop_var2,
     col = "red",
     cex = 2,
     lwd = 2,
     type = "b",
     xlab = "Thành phần chính",
     ylab = "Tỉ lệ",
     main = "Tỉ lệ các thành phần (dùng ma trận tương quan)"
)
```

Tỉ lệ các thành phần (dùng ma trận tương quan)



(4) Vẽ biểu đồ hai thành phần trong trường hợp sử dụng ma trận tương quan.

```
library(showtext)
font_add("LM", "C:/Windows/Fonts/cambria.ttc")
showtext_auto()

pcacov <- princomp(df, cor = TRUE)

biplot(pcacov,
  col = c(2, 4),
  cex = c(.5, 1.25),
  xlab = "Thành phần chính thứ nhất",
  ylab = "Thành phần chính thứ hai",
  main = "Biểu đồ hai thành phần (sử dụng ma trận tương quan)"
)
```

```
factanal(df, factors = 4)
```

5

```
##               Factor1 Factor2 Factor3 Factor4
## SS loadings      7.829   1.650   1.084   0.507
## Proportion Var    0.652   0.138   0.090   0.042
## Cumulative Var    0.652   0.790   0.880   0.922
##
## Test of the hypothesis that 4 factors are sufficient.
## The chi square statistic is 49.78 on 24 degrees of freedom.
## The p-value is 0.00151
```

(6) Với nhiều nhân tố hơn, hãy cho biết cần bao nhiêu nhân tố để tỉ lệ tổng phương sai lớn hơn 99%. Khi đó hãy cho biết biến “CONT” và “CFMG” được viết thông qua các nhân tố " F_i " như thế nào?

```
fa7 <- factanal(df, factors = 7)
fa7$loadings
```

```
##
## Loadings:
##      Factor1 Factor2 Factor3 Factor4 Factor5 Factor6 Factor7
## CONT              0.994
## INTG  0.578   0.783   0.143
## DMNR  0.520   0.795   0.262  -0.119
## DILG  0.872   0.435   0.159              -0.142
## CFMG  0.845   0.381   0.303   0.130
## DECI  0.870   0.346   0.293              0.164
## PREP  0.863   0.445   0.214
## FAMI  0.862   0.425   0.220          -0.102   0.104
## ORAL  0.787   0.527   0.304
## WRIT  0.819   0.507   0.236
## PHYS  0.626   0.368   0.674
## RTEN  0.696   0.611   0.367
##
##      Factor1 Factor2 Factor3 Factor4 Factor5 Factor6 Factor7
## SS loadings      6.493   3.127   1.123   1.040   0.059   0.048   0.016
## Proportion Var    0.541   0.261   0.094   0.087   0.005   0.004   0.001
## Cumulative Var    0.541   0.802   0.895   0.982   0.987   0.991   0.992
```

(7) Trong phân tích nhân tố nói trên, hãy cho biết 4 nhân tố đã đủ để giải thích bộ dữ liệu hay chưa, nếu chưa thì hãy cho biết cần bao nhiêu nhân tố? Xét ở mức ý nghĩa 5% cho kiểm định đó.

```
factanal(df, factors = 5)
```

```
##
## Call:
## factanal(x = df, factors = 5)
##
## Uniquenesses:
##  CONT  INTG  DMNR  DILG  CFMG  DECI  PREP  FAMI  ORAL  WRIT  PHYS  RTEN
## 0.693 0.021 0.025 0.005 0.005 0.028 0.007 0.005 0.005 0.005 0.016 0.007
##
## Loadings:
##      Factor1 Factor2 Factor3 Factor4 Factor5
## CONT              0.551
## INTG  0.687   0.644   0.182  -0.242
## DMNR  0.615   0.694   0.286  -0.183
## DILG  0.908   0.336   0.180              0.156
## CFMG  0.849   0.363   0.291   0.237
## DECI  0.864   0.320   0.296   0.186
```

```
## PREP 0.912 0.319 0.243
## FAMI 0.917 0.279 0.257
## ORAL 0.845 0.411 0.330
## WRIT 0.878 0.382 0.266
## PHYS 0.640 0.313 0.684
## RTEN 0.758 0.510 0.392
##
## Factor1 Factor2 Factor3 Factor4 Factor5
## SS loadings 7.283 2.097 1.246 0.510 0.047
## Proportion Var 0.607 0.175 0.104 0.042 0.004
## Cumulative Var 0.607 0.782 0.885 0.928 0.932
##
## Test of the hypothesis that 5 factors are sufficient.
## The chi square statistic is 31.85 on 16 degrees of freedom.
## The p-value is 0.0105
```

Câu 2. Bộ dữ liệu **wdbc kdevine** trong R được thu thập từ Bệnh viện Đại học Wisconsin, Madison, và được sử dụng để hỗ trợ trong việc chẩn đoán ung thư vú thông qua các đặc điểm của tế bào. Bộ dữ liệu gồm 569 quan sát và 31 biến, cụ thể các đặc trưng: Radius (Độ dài trung bình từ tâm đến các điểm trên chu vi), Texture (Độ lệch chuẩn của các giá trị xám), Perimeter (Chu vi của tế bào), Area (Diện tích của tế bào), Smoothness (Biến thiên cục bộ trong độ dài bán kính), Compactness (Tính toán từ chu vi và diện tích), Concavity (Mức độ nghiêm trọng của các phần lõm trên đường viền), Concave Points (Số lượng phần lõm trên đường viền), Symmetry (Độ đối xứng của tế bào), Fractal Dimension (Đánh giá độ phức tạp của hình dạng tế bào).

(1) Tiến hành tiền xử lý dữ liệu, bao gồm việc loại bỏ các cột không cần thiết và chuyển đổi các biến phân loại thành biến số.

```
library(kdevine)
```

```
## The kdevine package is no longer actively developed. Consider using
## - the 'kdeId' package for marginal estimation,
## - the functions vine() and vinecop() from the 'rvinecopulib'
## package as replacements for kdevine() and kdevinecop().
```

```
df <- wdbc
```

```
df$ID <- NULL
```

```
df[, 1] <- as.numeric(df[, 1]) - 1
```

```
head(df)
```

```
## diagnosis mean radius mean texture mean perimeter mean area mean smoothness
## 1 1 17.99 10.38 122.80 1001.0 0.11840
## 2 1 20.57 17.77 132.90 1326.0 0.08474
## 3 1 19.69 21.25 130.00 1203.0 0.10960
## 4 1 11.42 20.38 77.58 386.1 0.14250
## 5 1 20.29 14.34 135.10 1297.0 0.10030
## 6 1 12.45 15.70 82.57 477.1 0.12780
## mean compactness mean concavity mean concave points mean symmetry
## 1 0.27760 0.3001 0.14710 0.2419
## 2 0.07864 0.0869 0.07017 0.1812
## 3 0.15990 0.1974 0.12790 0.2069
## 4 0.28390 0.2414 0.10520 0.2597
## 5 0.13280 0.1980 0.10430 0.1809
## 6 0.17000 0.1578 0.08089 0.2087
## mean fractal dimension worst radius worst texture worst perimeter worst area
```

```
## 1      0.07871      1.0950      0.9053      8.589      153.40
## 2      0.05667      0.5435      0.7339      3.398      74.08
## 3      0.05999      0.7456      0.7869      4.585      94.03
## 4      0.09744      0.4956      1.1560      3.445      27.23
## 5      0.05883      0.7572      0.7813      5.438      94.44
## 6      0.07613      0.3345      0.8902      2.217      27.19
## worst smoothness worst compactness worst concavity worst concave points
## 1      0.006399      0.04904      0.05373      0.01587
## 2      0.005225      0.01308      0.01860      0.01340
## 3      0.006150      0.04006      0.03832      0.02058
## 4      0.009110      0.07458      0.05661      0.01867
## 5      0.011490      0.02461      0.05688      0.01885
## 6      0.007510      0.03345      0.03672      0.01137
## worst symmetry worst fractal dimension sd radius sd texture sd perimeter
## 1      0.03003      0.006193      25.38      17.33      184.60
## 2      0.01389      0.003532      24.99      23.41      158.80
## 3      0.02250      0.004571      23.57      25.53      152.50
## 4      0.05963      0.009208      14.91      26.50      98.87
## 5      0.01756      0.005115      22.54      16.67      152.20
## 6      0.02165      0.005082      15.47      23.75      103.40
## sd area sd smoothness sd compactness sd concavity sd concave points
## 1      2019.0      0.1622      0.6656      0.7119      0.2654
## 2      1956.0      0.1238      0.1866      0.2416      0.1860
## 3      1709.0      0.1444      0.4245      0.4504      0.2430
## 4      567.7      0.2098      0.8663      0.6869      0.2575
## 5      1575.0      0.1374      0.2050      0.4000      0.1625
## 6      741.6      0.1791      0.5249      0.5355      0.1741
## sd symmetry sd fractal dimension
## 1      0.4601      0.11890
## 2      0.2750      0.08902
## 3      0.3613      0.08758
## 4      0.6638      0.17300
## 5      0.2364      0.07678
## 6      0.3985      0.12440
```

(2) Chuẩn hóa dữ liệu để đảm bảo rằng tất cả các biến có cùng quy mô.

```
df_scaled <- scale(df)
```

```
apply(df_scaled, 2, mean)
```

```
##      diagnosis      mean radius      mean texture
##      7.061834e-17      -1.379776e-16      6.157678e-17
##      mean perimeter      mean area      mean smoothness
##      -1.190559e-16      1.219971e-16      1.618800e-16
##      mean compactness      mean concavity      mean concave points
##      -7.605173e-17      3.929080e-17      -5.337457e-17
##      mean symmetry mean fractal dimension      worst radius
##      1.679646e-16      4.810260e-16      3.721164e-17
##      worst texture      worst perimeter      worst area
##      -1.065855e-16      1.074950e-16      2.873226e-17
##      worst smoothness      worst compactness      worst concavity
##      1.290824e-16      -1.610869e-17      -5.978051e-17
##      worst concave points      worst symmetry worst fractal dimension
##      7.922107e-18      9.126277e-17      1.564424e-18
##      sd radius      sd texture      sd perimeter
##      -8.483720e-17      9.038321e-18      5.661517e-17
```



```
##          sd area          sd smoothness          sd compactness
##      6.734248e-18      -2.269302e-16      1.261676e-17
##          sd concavity      sd concave points          sd symmetry
##      9.174370e-17          1.166365e-17      2.760417e-16
##      sd fractal dimension
##      2.002241e-16
```

```
apply(df_scaled, 2, sd)
```

```
##          diagnosis          mean radius          mean texture
##              1              1              1
##      mean perimeter          mean area          mean smoothness
##              1              1              1
##      mean compactness          mean concavity          mean concave points
##              1              1              1
##      mean symmetry      mean fractal dimension          worst radius
##              1              1              1
##      worst texture          worst perimeter          worst area
##              1              1              1
##      worst smoothness          worst compactness          worst concavity
##              1              1              1
##      worst concave points          worst symmetry      worst fractal dimension
##              1              1              1
##          sd radius          sd texture          sd perimeter
##              1              1              1
##          sd area          sd smoothness          sd compactness
##              1              1              1
##          sd concavity          sd concave points          sd symmetry
##              1              1              1
##      sd fractal dimension
##              1
```

(3) Tính toán ma trận hiệp phương sai và tìm giá trị riêng, vector riêng.

```
cov_matrix <- cov(df_scaled)
```

```
eigen_result <- eigen(cov_matrix)
```

```
eigen_values <- eigen_result$values
```

```
eigen_vectors <- eigen_result$vectors
```

```
eigen_values
```

```
## [1] 1.391777e+01 5.726352e+00 2.846849e+00 1.998363e+00 1.659079e+00
## [6] 1.207508e+00 6.847192e-01 4.848554e-01 4.168948e-01 3.508936e-01
## [11] 3.048554e-01 2.909858e-01 2.610104e-01 2.122756e-01 1.485762e-01
## [16] 8.816256e-02 7.986017e-02 5.903533e-02 5.146191e-02 4.821595e-02
## [21] 3.070628e-02 2.952665e-02 2.734467e-02 2.428359e-02 1.755221e-02
## [26] 1.547334e-02 8.056144e-03 6.869732e-03 1.588467e-03 7.416788e-04
## [31] 1.326347e-04
```

(4) Thực hiện PCA và phân tích kết quả. Sau đó, vẽ các biểu đồ liên quan đến PCA, bao gồm biplot, biểu đồ tỷ lệ phương sai giải thích và biểu đồ phân tán các thành phần chính.

```
pca <- princomp(df_scaled)
```


```
summary(pca)
```

```
## Importance of components:
##               Comp.1   Comp.2   Comp.3   Comp.4   Comp.5
## Standard deviation 3.7273732 2.3908760 1.68577763 1.41239197 1.28691989
## Proportion of Variance 0.4489604 0.1847210 0.09183385 0.06446333 0.05351866
## Cumulative Proportion 0.4489604 0.6336814 0.72551525 0.78997857 0.84349724
##               Comp.6   Comp.7   Comp.8   Comp.9   Comp.10
## Standard deviation 1.09790061 0.82675013 0.6957035 0.64510631 0.59184200
## Proportion of Variance 0.03895187 0.02208771 0.0156405 0.01344822 0.01131915
## Cumulative Proportion 0.88244910 0.90453682 0.9201773 0.93362554 0.94494469
##               Comp.11   Comp.12   Comp.13   Comp.14
## Standard deviation 0.551651721 0.53895681 0.510442654 0.460328668
## Proportion of Variance 0.009834045 0.00938664 0.008419691 0.006847598
## Cumulative Proportion 0.954778732 0.96416537 0.972585063 0.979432661
##               Comp.15   Comp.16   Comp.17   Comp.18
## Standard deviation 0.38511695 0.296660781 0.282346987 0.242758270
## Proportion of Variance 0.00479278 0.002843954 0.002576135 0.001904366
## Cumulative Proportion 0.98422544 0.987069395 0.989645529 0.991549895
##               Comp.19   Comp.20   Comp.21   Comp.22
## Standard deviation 0.226652742 0.219388265 0.1750780211 0.1716821445
## Proportion of Variance 0.001660062 0.001555353 0.0009905251 0.0009524726
## Cumulative Proportion 0.993209957 0.994765310 0.9957558349 0.9967083075
##               Comp.23   Comp.24   Comp.25   Comp.26
## Standard deviation 0.165216858 0.1556949415 0.1323683001 0.1242825166
## Proportion of Variance 0.000882086 0.0007833417 0.0005662005 0.0004991399
## Cumulative Proportion 0.997590394 0.9983737352 0.9989399357 0.9994390756
##               Comp.27   Comp.28   Comp.29   Comp.30
## Standard deviation 0.0896771168 0.0828109811 3.982054e-02 2.720984e-02
## Proportion of Variance 0.0002598756 0.0002216043 5.124088e-05 2.392512e-05
## Cumulative Proportion 0.9996989512 0.9999205555 9.999718e-01 9.999957e-01
##               Comp.31
## Standard deviation 1.150659e-02
## Proportion of Variance 4.278539e-06
## Cumulative Proportion 1.000000e+00
```

```
var <- pca$sdev^2 / sum(pca$sdev^2)
```


```
plot(var,
      col = "red",
      cex = 2,
      lwd = 2,
      type = "b",
      xlab = "Thành phần chính",
      ylab = "Tỷ lệ",
      main = "Tỷ lệ các thành phần (phân tích trên bộ dữ liệu)"
)
```

Tỉ lệ các thành phần (phân tích trên bộ dữ liệu)



```
biplot(pca,  
  col = c(2, 4),  
  cex = c(.5, 1.25),  
  xlab = "Thành phần chính thứ nhất",  
  ylab = "Thành phần chính thứ hai",  
  main = "Biểu đồ hai thành phần (sử dụng ma trận tương quan)"  
)
```

Biểu đồ hai thành phần (sử dụng ma trận tương quan)



(5) Viết nhận xét về kết quả phân tích và ý nghĩa của các thành phần chính.

Thành phần chính thứ nhất giải thích khoảng 45% dữ liệu.

Thành phần chính thứ hai giải thích khoảng 18% dữ liệu.

Thành phần chính thứ ba giải thích khoảng 9% dữ liệu.

...

7 thành phần chính đầu tiên giải thích khoảng 90% dữ liệu.

11 thành phần chính đầu tiên giải thích khoảng 95% dữ liệu.

17 thành phần chính đầu tiên giải thích khoảng 99% dữ liệu.